critic-bench

Тест ИИ-моделей в роли критика кода: найти ошибки в чужом коде, предложить исправление и подход лучше. · обновлено 04.11.2026

Это тест критика и советчика, а не написания кода. Модель получает задание и готовый код и одним ответом, без инструментов и запуска, перечисляет найденные ошибки с исправлениями и предлагает решения лучше. Результат говорит, кого звать на ревью, но не кому поручать писать проект.

Измеряет

- внимательность к реальным ошибкам, особенно серьёзным;
- умение не выдумывать — ложные замечания штрафуются;
- качество предложенного исправления;
- умение увидеть подход лучше точечной заплатки.

Не измеряет

- написание приложений и архитектуру с нуля;
- агентную работу: чтение проекта, запуск, проверку догадок;
- работу с большими проектами — в тестах 1–3 файла;
- стабильность: у каждой модели один прогон, разброс ±10–15 баллов.

Общий рейтинг

Общий балл = 20 % × тест 1 + 40 % × тест 2 + 40 % × тест 3. Тест 1 лёгкий, поэтому весит меньше. Уровни: лидеры ≥ 50, сильные 40–50, средние 30–40, слабые < 30. **Внутри уровня порядок во многом случаен** — у каждой модели один прогон. «Серьёзные» — сколько серьёзных находок из всех, что нашла хоть одна модель, нашла эта.

#	МОДЕЛЬ	СЕМЕЙСТВО	ТЕСТ 1 МАГАЗИН	ТЕСТ 2 ЗАГРУЗЧИК	ТЕСТ 3 МАРШРУТЫ A*	ОБЩИЙ	СЕРЬЁЗНЫЕ	ДОСТУП	ПОМЕТКА
лидеры									
1	**Claude Haiku 5.5**	Anthropic	88.9	46.2	69.9	**64.2**	6 из 6	Claude Code, xhigh	
2	**Gemini Argon · high**	Google	91.1	43.8	70.9	**64.1**	5 из 6	веб Gemini, high	
3	**GPT-6.1 Terra Pro**	OpenAI	93.7	38.5	59.4	**57.9**	6 из 6	OpenRouter, high	
4	**Claude Opus 5.5**	Anthropic	97.6	27.1	66.6	**57.0**	5 из 6	Claude Code, xhigh	
5	**GPT-6.1 Sol**	OpenAI	91.4	34.1	61.2	**56.4**	6 из 6	OpenRouter, high	
6	**Claude Sonnet 5.5**	Anthropic	91.8	26.3	62.3	**53.8**	5 из 6	Claude Code, xhigh	
сильные									
7	**Grok 4.7**	xAI	84.9	46.4	33.8	**49.1**	5 из 6	OpenRouter, high	
8	**Kimi K3.1 Pro**	Moonshot	84.6	28.9	51.1	**48.9**	6 из 6	OpenRouter, high	
9	**MiMo V2.6 Pro**	Xiaomi	86.6	18.5	57.9	**47.9**	5 из 6	OpenRouter, high	

#	МОДЕЛЬ ↕	СЕМЕЙСТВО ↕	ТЕСТ 1 МАГАЗИН ↕	ТЕСТ 2 ЗАГРУЗЧИК ↕	ТЕСТ 3 МАРШРУТЫ A* ↕	ОБЩИЙ ↕	СЕРЬЁЗНЫЕ ↕	ДОСТУП	ПОМЕТКА
10	**Qwen 3.8 Max Prime**	Qwen	87.9	33.0	37.9	**45.9**	5 из 6	OpenRouter, high	
11	**MiniMax M3**	MiniMax	97.7	49.4	10.8	**43.6**	5 из 6	OpenRouter, high	
12	**Gemini Argon · medium**	Google	84.6	33.4	28.7	**41.8**	5 из 6	веб Gemini, medium	
13	**DeepSeek V4.1 Flash**	DeepSeek	76.3	14.9	50.2	**41.3**	5 из 6	OpenRouter, high	
14	**Step 5 Preview**	StepFun	84.5	34.8	24.0	**40.4**	6 из 6	OpenRouter, high	
средние									
15	**Gemini 3.1 Pro**	Google	75.3	0.1	55.3	**37.2**	5 из 6	веб Gemini, high	
16	**Mistral Large 4**	Mistral	84.1	4.2	38.3	**33.8**	5 из 6	Mistral API	
17	**Gemini 3.8 Flash**	Google	76.7	12.5	33.4	**33.7**	4 из 6	Antigravity, high	
18	**Muse Spark**	Meta	79.6	8.7	31.3	**31.9**	4 из 6	OpenRouter, high	
слабые									
19	**DeepSeek V4 Pro**	DeepSeek	81.0	6.9	18.0	**26.2**	4 из 6	OpenRouter, high	тест 1: не по формату, разобран вручную
20	**Nemotron 3 Ultra**	NVIDIA	74.8	0.0	27.1	**25.8**	5 из 6	NVIDIA	
вне общего рейтинга									
	Muse Wonder	Meta	86.6	—	—	—	4 из 4	OpenRouter, high	исключена из-за цены
	GLM 5.3 Prime	Z.ai	84.0	14.3	—	—	4 из 5	OpenRouter, high	тест 3 не прогнан (бюджет)
	Muse Glimmer 30B	Meta	71.9	—	—	—	4 из 4	NVIDIA	отсеяна тестом 1
	Claude Opus 4.6	Anthropic	68.3	—	—	—	4 из 4	Antigravity	есть модель новее
	GPT-OSS 120B	OpenAI	64.6	—	—	—	4 из 4	Groq, medium	отсеяна тестом 1
	GPT-OSS 20B	OpenAI	63.1	—	—	—	4 из 4	Groq, medium	отсеяна тестом 1
	Mistral Medium 3.5	Mistral	60.9	—	—	—	4 из 4	OpenRouter	отсеяна тестом 1

#	МОДЕЛЬ ↕	СЕМЕЙСТВО ↕	ТЕСТ 1 МАГАЗИН ↕	ТЕСТ 2 ЗАГРУЗЧИК ↕	ТЕСТ 3 МАРШРУТЫ A* ↕	ОБЩИЙ ↕	СЕРЬЁЗНЫЕ ↕	ДОСТУП	ПОМЕТКА
	North Mini Code	Cohere	**60.6**	—	—	—	4 из 4	OpenRouter	отсеяна тестом 1
	Laguna XS 2.1	Poolside	**53.4**	—	—	—	3 из 4	NVIDIA	отсеяна тестом 1
	Command A+	Cohere	**53.2**	—	—	—	3 из 4	OpenRouter	отсеяна тестом 1
	Ministral 14B	Mistral	**47.4**	—	—	—	3 из 4	Mistral API	отсеяна тестом 1
	Nemotron 3.5 Lightning 30B	NVIDIA	**47.0**	—	—	—	3 из 4	NVIDIA	отсеяна тестом 1
	Codestral	Mistral	**33.1**	—	—	—	2 из 4	Mistral API	отсеяна тестом 1
	LFM 2.5 2.6B	Liquid	**22.8**	—	—	—	2 из 4	OpenRouter	отсеяна тестом 1
	Ministral 8B	Mistral	**20.6**	—	—	—	2 из 4	Mistral API	отсеяна тестом 1
	Nemotron 3.5 Bolt E4B	NVIDIA	**6.9**	—	—	—	0 из 4	NVIDIA	отсеяна тестом 1
	Ministral 3B	Mistral	**0.0**	—	—	—	2 из 4	Mistral API	отсеяна тестом 1

Сортировка — по клику на заголовок (уровни при этом скрываются; вернуть — обновить страницу). «Отсеяна тестом 1» — слабый результат на лёгком тесте, на реальный код модель не отправлялась.

Тест 1 · Магазин Python вес в общем 20 %

Учебный сервис заказов (3 файла, ~150 строк) с заложенными ошибками и ловушками — правильным кодом, похожим на ошибку. Лёгкий: отсеивает слабые модели.

Моделей: 37, семейств: 17. Реальных находок и предложений: 19, из них серьёзных: 4. 100 баллов — всё, что нашёл кто-либо, с верными исправлениями и без ложных.

#	МОДЕЛЬ ↕	БАЛЛ ↕	СЕРЬЁЗНЫЕ ↕	РЕАЛЬНЫХ ↕	ЛОЖНЫХ (ШТРАФ) ↕
1	**MiniMax M3** MiniMax	97.7	4 из 4	18	0
2	**Claude Opus 5.5** Anthropic	97.6	4 из 4	18	0
3	**GPT-6.1 Terra Pro** OpenAI	93.7	4 из 4	16	0
4	**Claude Sonnet 5.5** Anthropic	91.8	4 из 4	15	0
5	**GPT-6.1 Sol** OpenAI	91.4	4 из 4	15	0
6	**Gemini Argon · high** Google	91.1	4 из 4	15	0
7	**Claude Haiku 5.5** Anthropic	88.9	4 из 4	16	0
8	**Qwen 3.8 Max Prime** Qwen	87.9	4 из 4	13	0
9	**MiMo V2.6 Pro** Xiaomi	86.6	4 из 4	15	0
10	**Muse Wonder** Meta	86.6	4 из 4	15	0
11	**Grok 4.7** xAI	84.9	4 из 4	14	0
12	**Kimi K3.1 Pro** Moonshot	84.6	4 из 4	14	0
13	**Gemini Argon · medium** Google	84.6	4 из 4	14	0
14	**Step 5 Preview** StepFun	84.5	4 из 4	15	0
15	**Mistral Large 4** Mistral	84.1	4 из 4	15	0
16	**GLM 5.3 Prime** Z.ai	84.0	4 из 4	15	0
17	**DeepSeek V4 Pro** DeepSeek	81.0	4 из 4	14	0
18	**Muse Spark** Meta	79.6	4 из 4	13	0
19	**Gemini 3.8 Flash** Google	76.7	4 из 4	12	0
20	**DeepSeek V4.1 Flash** DeepSeek	76.3	4 из 4	12	0

#	МОДЕЛЬ	БАЛЛ	СЕРЬЁЗНЫЕ	РЕАЛЬНЫХ	ЛОЖНЫХ (ШТРАФ)
21	**Gemini 3.1 Pro** Google	75.3	4 из 4	12	0
22	**Nemotron 3 Ultra** NVIDIA	74.8	4 из 4	13	0
23	**Muse Glimmer 30B** Meta	71.9	4 из 4	10	0
24	**Claude Opus 4.6** Anthropic	68.3	4 из 4	11	0
25	**GPT-OSS 120B** OpenAI	64.6	4 из 4	9	0
26	**GPT-OSS 20B** OpenAI	63.1	4 из 4	9	0
27	**Mistral Medium 3.5** Mistral	60.9	4 из 4	8	0
28	**North Mini Code** Cohere	60.6	4 из 4	9	1 (−3)
29	**Laguna XS 2.1** Poolside	53.4	3 из 4	9	0
30	**Command A+** Cohere	53.2	3 из 4	7	0
31	**Ministral 14B** Mistral	47.4	3 из 4	9	0
32	**Nemotron 3.5 Lightning 30B** NVIDIA	47.0	3 из 4	6	0
33	**Codestral** Mistral	33.1	2 из 4	5	0
34	**LFM 2.5 2.6B** Liquid	22.8	2 из 4	3	0
35	**Ministral 8B** Mistral	20.6	2 из 4	7	1 (−9)
36	**Nemotron 3.5 Bolt E4B** NVIDIA	6.9	0 из 4	3	1 (−3)
37	**Ministral 3B** Mistral	0.0	2 из 4	5	5 (−45)

Находки и предложения — от самых ценных

3 серьёзная 2 заметная 1 мелкая ● верное исправление ◐ частичное ○ нет / неверное ✓ найдено (у мелких и «лучше» исправление не оценивается)

▾ **3** купон — доля, apply_discount ждёт проценты; итог float — 33 мод. · 16 сем.

pricing.py:10-14, orders.py:54 · серьёзная · цена 9.53

● MiniMax M3 · ● Claude Opus 5.5 · ● GPT-6.1 Terra Pro · ● Claude Sonnet 5.5 · ● GPT-6.1 Sol · ● Gemini Argon · high · ● Claude Haiku 5.5 · ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro · ● Muse Wonder · ● Grok 4.7 · ● Kimi K3.1 Pro · ● Gemini Argon · medium · ◐ Step 5 Preview · ◐ Mistral Large 4 · ● GLM 5.3 Prime · ✓ DeepSeek V4 Pro
◐ Muse Spark · ● Gemini 3.8 Flash · ◐ DeepSeek V4.1 Flash · ◐ Gemini 3.1 Pro · ◐ Nemotron 3 Ultra · ● Muse Glimmer 30B · ◐ Claude Opus 4.6 · ● GPT-OSS 120B
◐ GPT-OSS 20B · ◐ Mistral Medium 3.5 · ◐ North Mini Code · ● Command A+ · ◐ Ministral 14B · ◐ Nemotron 3.5 Lightning 30B · ◐ Codestral · ○ LFM 2.5 2.6B

▾ **3** date >= datetime — TypeError на любом купоне — 33 мод. · 16 сем.

pricing.py:25-27 · серьёзная · цена 9.53

● MiniMax M3 · ● Claude Opus 5.5 · ● GPT-6.1 Terra Pro · ● Claude Sonnet 5.5 · ● GPT-6.1 Sol · ● Gemini Argon · high · ● Claude Haiku 5.5 · ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro · ● Muse Wonder · ● Grok 4.7 · ● Kimi K3.1 Pro · ● Gemini Argon · medium · ● Step 5 Preview · ● Mistral Large 4 · ● GLM 5.3 Prime · ✓ DeepSeek V4 Pro
● Muse Spark · ● Gemini 3.8 Flash · ● DeepSeek V4.1 Flash · ● Gemini 3.1 Pro · ● Nemotron 3 Ultra · ● Muse Glimmer 30B · ● Claude Opus 4.6 · ● GPT-OSS 120B · ● GPT-OSS 20B
● Mistral Medium 3.5 · ● North Mini Code · ● Laguna XS 2.1 · ● Command A+ · ○ Ministral 14B · ● Nemotron 3.5 Lightning 30B · ○ Ministral 3B

▾ **3** проверка остатка вне блокировки — 31 мод. · 16 сем.

orders.py:27-31 · серьёзная · цена 9.53

● MiniMax M3 · ● Claude Opus 5.5 · ● GPT-6.1 Terra Pro · ● Claude Sonnet 5.5 · ● GPT-6.1 Sol · ● Gemini Argon · high · ● Claude Haiku 5.5 · ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro · ● Muse Wonder · ● Grok 4.7 · ● Kimi K3.1 Pro · ● Gemini Argon · medium · ● Step 5 Preview · ● Mistral Large 4 · ● GLM 5.3 Prime · ✓ DeepSeek V4 Pro
● Muse Spark · ● Gemini 3.8 Flash · ● DeepSeek V4.1 Flash · ● Gemini 3.1 Pro · ● Nemotron 3 Ultra · ● Muse Glimmer 30B · ● Claude Opus 4.6 · ● GPT-OSS 120B · ● GPT-OSS 20B
● Mistral Medium 3.5 · ● North Mini Code · ● Laguna XS 2.1 · ● Nemotron 3.5 Lightning 30B · ○ Ministral 8B

▾ **3** SQL-инъекция через email — 35 мод. · 17 сем.

storage.py:35-38 · серьёзная · цена 9

● MiniMax M3 · ● Claude Opus 5.5 · ● GPT-6.1 Terra Pro · ● Claude Sonnet 5.5 · ● GPT-6.1 Sol · ● Gemini Argon · high · ● Claude Haiku 5.5 · ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro · ● Muse Wonder · ● Grok 4.7 · ● Kimi K3.1 Pro · ● Gemini Argon · medium · ● Step 5 Preview · ● Mistral Large 4 · ● GLM 5.3 Prime · ✓ DeepSeek V4 Pro
● Muse Spark · ● Gemini 3.8 Flash · ● DeepSeek V4.1 Flash · ● Gemini 3.1 Pro · ● Nemotron 3 Ultra · ● Muse Glimmer 30B · ● Claude Opus 4.6 · ● GPT-OSS 120B · ● GPT-OSS 20B
● Mistral Medium 3.5 · ● North Mini Code · ● Laguna XS 2.1 · ● Command A+ · ● Ministral 14B · ● Codestral · ● LFM 2.5 2.6B · ● Ministral 8B · ● Ministral 3B

▾ 2 **Лучше:** пагинация в SQL (LIMIT/OFFSET) — снимает лишнюю запись на странице и отрицательный сдвиг, не грузит всё в память — 8 мод. · 6 сем.

предложение · цена 4.94

✓ MiniMax M3 ✓ Claude Opus 5.5 ✓ GPT-6.1 Terra Pro ✓ Claude Sonnet 5.5 ✓ GPT-6.1 Sol ✓ Gemini Argon · high ✓ Qwen 3.8 Max Prime ✓ Muse Spark

▾ 2 нет проверки qty > 0 — 23 мод. · 13 сем.

orders.py:43-45 · заметная · цена 3.71

● MiniMax M3 ● Claude Opus 5.5 ● GPT-6.1 Terra Pro ● Claude Sonnet 5.5 ● GPT-6.1 Sol ● Gemini Argon · high ● Claude Haiku 5.5 ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro ● Muse Wonder ● Grok 4.7 ● Kimi K3.1 Pro ● Gemini Argon · medium ● Step 5 Preview ● Mistral Large 4 ✓ DeepSeek V4 Pro ● Muse Spark
● DeepSeek V4.1 Flash ◐ Gemini 3.1 Pro ◐ Nemotron 3 Ultra ◐ Mistral Medium 3.5 ◐ Codestral ○ Nemotron 3.5 Bolt E4B

▾ 2 **Лучше:** атомарный условный UPDATE статуса — снимает повторный возврат, возврат товара до смены статуса и гонку — 18 мод. · 13 сем.

предложение · цена 3.71

✓ MiniMax M3 ✓ Claude Opus 5.5 ✓ GPT-6.1 Terra Pro ✓ Claude Sonnet 5.5 ✓ GPT-6.1 Sol ✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ Qwen 3.8 Max Prime
✓ MiMo V2.6 Pro ✓ Muse Wonder ✓ Grok 4.7 ✓ Kimi K3.1 Pro ✓ Gemini Argon · medium ✓ Step 5 Preview ✓ Mistral Large 4 ✓ GLM 5.3 Prime ✓ Gemini 3.8 Flash
✓ DeepSeek V4.1 Flash

▾ 2 резерв не возвращается при сбое после резервирования — 22 мод. · 14 сем.

orders.py:41-59 · заметная · цена 3.53

● MiniMax M3 ● Claude Opus 5.5 ● GPT-6.1 Terra Pro ● Claude Sonnet 5.5 ● GPT-6.1 Sol ● Gemini Argon · high ● Claude Haiku 5.5 ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro ● Muse Wonder ● Grok 4.7 ● Kimi K3.1 Pro ● Gemini Argon · medium ● Step 5 Preview ◐ Mistral Large 4 ● GLM 5.3 Prime ✓ DeepSeek V4 Pro
○ Gemini 3.8 Flash ● Gemini 3.1 Pro ● Nemotron 3 Ultra ● Muse Glimmer 30B ○ Ministral 14B

▾ 2 > вместо >= для бесплатной доставки — 31 мод. · 16 сем.

pricing.py:21-23 · заметная · цена 3.18

● MiniMax M3 ● Claude Opus 5.5 ● GPT-6.1 Terra Pro ● Claude Sonnet 5.5 ● GPT-6.1 Sol ● Gemini Argon · high ● Claude Haiku 5.5 ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro ● Muse Wonder ● Grok 4.7 ● Kimi K3.1 Pro ● Gemini Argon · medium ● Step 5 Preview ● Mistral Large 4 ● GLM 5.3 Prime ✓ DeepSeek V4 Pro
● Muse Spark ● Gemini 3.8 Flash ● DeepSeek V4.1 Flash ● Gemini 3.1 Pro ● Nemotron 3 Ultra ● Muse Glimmer 30B ● Claude Opus 4.6 ● GPT-OSS 120B ● GPT-OSS 20B
● Mistral Medium 3.5 ● North Mini Code ● Laguna XS 2.1 ● Command A+ ● Nemotron 3.5 Lightning 30B

▾ **2** лишний заказ на странице — 35 мод. · 16 сем.

storage.py:40-41 · заметная · цена 3.18

● MiniMax M3 ● Claude Opus 5.5 ● GPT-6.1 Terra Pro ● Claude Sonnet 5.5 ● GPT-6.1 Sol ● Gemini Argon · high ● Claude Haiku 5.5 ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro ● Muse Wonder ● Grok 4.7 ● Kimi K3.1 Pro ● Gemini Argon · medium ● Step 5 Preview ● Mistral Large 4 ● GLM 5.3 Prime ● Muse Spark
● Gemini 3.8 Flash ● DeepSeek V4.1 Flash ● Gemini 3.1 Pro ● Nemotron 3 Ultra ● Muse Glimmer 30B ● Claude Opus 4.6 ● GPT-OSS 120B ● GPT-OSS 20B
● Mistral Medium 3.5 ● North Mini Code ● Laguna XS 2.1 ● Command A+ ● Ministral 14B ● Nemotron 3.5 Lightning 30B ● Codestral ● Ministral 8B
● Nemotron 3.5 Bolt E4B ● Ministral 3B

▾ **2** tags=[] по умолчанию — 32 мод. · 16 сем.

orders.py:37 · заметная · цена 3.18

● MiniMax M3 ● Claude Opus 5.5 ● GPT-6.1 Terra Pro ● Claude Sonnet 5.5 ● GPT-6.1 Sol ● Gemini Argon · high ● Claude Haiku 5.5 ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro ● Muse Wonder ● Grok 4.7 ● Kimi K3.1 Pro ● Gemini Argon · medium ● Step 5 Preview ● Mistral Large 4 ● GLM 5.3 Prime ✓ DeepSeek V4 Pro
● Muse Spark ● Gemini 3.8 Flash ● DeepSeek V4.1 Flash ● Gemini 3.1 Pro ◐ Nemotron 3 Ultra ● Muse Glimmer 30B ● Claude Opus 4.6 ● GPT-OSS 120B ◐ GPT-OSS 20B
● North Mini Code ◐ Laguna XS 2.1 ● Command A+ ◐ Nemotron 3.5 Lightning 30B ◐ Nemotron 3.5 Bolt E4B ○ Ministral 3B

▾ **2** повторный возврат того же объекта — 31 мод. · 16 сем.

orders.py:61-67 · заметная · цена 3.18

● MiniMax M3 ● Claude Opus 5.5 ● GPT-6.1 Terra Pro ● Claude Sonnet 5.5 ● GPT-6.1 Sol ● Gemini Argon · high ● Claude Haiku 5.5 ● Qwen 3.8 Max Prime
● MiMo V2.6 Pro ● Muse Wonder ● Grok 4.7 ● Kimi K3.1 Pro ● Gemini Argon · medium ● Step 5 Preview ● Mistral Large 4 ● GLM 5.3 Prime ✓ DeepSeek V4 Pro
● Muse Spark ● Gemini 3.8 Flash ● DeepSeek V4.1 Flash ● Gemini 3.1 Pro ○ Nemotron 3 Ultra ● Muse Glimmer 30B ● Claude Opus 4.6 ○ GPT-OSS 20B
◐ North Mini Code ● Command A+ ◐ Ministral 14B ○ Codestral ○ LFM 2.5 2.6B ○ Ministral 8B

▾ **1** **Лучше:** транзакция / контекст для резерва с откатом — резерв не теряется при сбое после резервирования — 3 мод. · 3 сем.

предложение · цена 1.82

✓ MiniMax M3 ✓ DeepSeek V4 Pro ✓ Ministral 14B

▾ 1 page < 1 — отрицательный сдвиг среза — 6 мод. · 4 сем.

storage.py:31-41 · мелкая · цена 1.76

✓ Claude Opus 5.5 ✓ Mistral Large 4 ✓ GLM 5.3 Prime ✓ DeepSeek V4 Pro ✓ Ministral 14B ✓ Ministral 8B

▾ 1 товар возвращается на склад до записи статуса — 6 мод. · 4 сем.

orders.py:64-66 · мелкая · цена 1.76

✓ MiniMax M3 ✓ Claude Opus 5.5 ✓ GPT-6.1 Terra Pro ✓ Claude Sonnet 5.5 ✓ Claude Haiku 5.5 ✓ DeepSeek V4 Pro

▾ 1 % и _ в email не экранированы в LIKE — 11 мод. · 9 сем.

storage.py:36 · мелкая · цена 1.47

✓ MiniMax M3 ✓ Claude Opus 5.5 ✓ GPT-6.1 Terra Pro ✓ GPT-6.1 Sol ✓ Claude Haiku 5.5 ✓ MiMo V2.6 Pro ✓ Muse Wonder ✓ Grok 4.7 ✓ Step 5 Preview ✓ GLM 5.3 Prime ✓ Laguna XS 2.1

▾ 1 tags.append меняет список вызывающего — 21 мод. · 13 сем.

orders.py:56 · мелкая · цена 1.24

✓ MiniMax M3 ✓ Claude Opus 5.5 ✓ Claude Sonnet 5.5 ✓ GPT-6.1 Sol ✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ MiMo V2.6 Pro ✓ Muse Wonder ✓ Grok 4.7 ✓ Kimi K3.1 Pro ✓ Gemini Argon · medium ✓ Step 5 Preview ✓ Mistral Large 4 ✓ GLM 5.3 Prime ✓ Muse Spark ✓ Gemini 3.1 Pro ✓ Nemotron 3 Ultra ✓ Muse Glimmer 30B ✓ Claude Opus 4.6 ✓ GPT-OSS 120B ✓ Laguna XS 2.1

▾ 1 тег coupon у недействительного купона — 23 мод. · 13 сем.

orders.py:56 · мелкая · цена 1.24

✓ MiniMax M3 ✓ Claude Opus 5.5 ✓ GPT-6.1 Terra Pro ✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ MiMo V2.6 Pro ✓ Muse Wonder ✓ Kimi K3.1 Pro ✓ Gemini Argon · medium ✓ Step 5 Preview ✓ Mistral Large 4 ✓ GLM 5.3 Prime ✓ DeepSeek V4 Pro ✓ Muse Spark ✓ Gemini 3.8 Flash ✓ DeepSeek V4.1 Flash ✓ Nemotron 3 Ultra ✓ Claude Opus 4.6 ✓ GPT-OSS 20B ✓ Mistral Medium 3.5 ✓ North Mini Code ✓ Ministral 14B ✓ Ministral 8B

▾ 1 соединение не закрывается при отсутствии купона 27 мод. · 15 сем.

storage.py:23-29 · мелкая · цена 1.12

✓ MiniMax M3 ✓ Claude Opus 5.5 ✓ GPT-6.1 Terra Pro ✓ Claude Sonnet 5.5 ✓ GPT-6.1 Sol ✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ Qwen 3.8 Max Prime ✓ MiMo V2.6 Pro ✓ Muse Wonder ✓ Grok 4.7 ✓ Kimi K3.1 Pro ✓ Gemini Argon · medium ✓ Step 5 Preview ✓ Mistral Large 4 ✓ GLM 5.3 Prime ✓ DeepSeek V4 Pro ✓ Muse Spark ✓ Gemini 3.8 Flash ✓ DeepSeek V4.1 Flash ✓ Gemini 3.1 Pro ✓ Nemotron 3 Ultra ✓ Claude Opus 4.6 ✓ GPT-OSS 120B ✓ Laguna XS 2.1 ✓ Ministral 8B ✓ Ministral 3B

▾ **Матрица «находка × модель»** — кто что нашёл

Находка	MiniMax M3	Claude Opus 5.5	GPT-6.1 Terra Pro	Claude Sonnet 5.5	GPT-6.1 Sol	Gemini Argon · high	Claude Haiku 5.5	Qwen 3.8 Max Prime	MiMo V2.6 Pro	Muse Wonder	Grok 4.7	Kimi K3.1 Pro	Gemini Argon · medium	Step 5 Preview	Mistral Large 4	GLM 5.3 Prime	DeepSeek V4 Pro	Muse Spark	Gemini 3.8 Flash	DeepSeek V4.1 Flash	Gemini 3.1 Pro	Nemotron 3 Ultra	Muse Glimmer 30B	Claude Opus 4.6	GPT-OSS 120B	GPT-OSS 20B	Mistral Medium 3.5	North Mini Code	Laguna XS 2.1	Command A+	Ministral 14B	Nemotron 3.5 Lightning 30	Codestral	LFM 2.5 2.6B	Ministral 8B	Nemotron 3.5 Bolt E4B	Ministral 3B
3 купон — доля, apply_discount ждёт проценты; итог float	●	●	●	●	●	●	●	●	●	●	●	●	●	◐	◐	●	✓	◐	●	◐	◐	◐	●	◐	●	◐	◐	◐		●	◐	◐	◐	○		
3 date >= datetime — TypeError на любом купоне	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	✓	●	●	●	●	●	●	●	●	●	●	●	●	○	●					○
3 проверка остатка вне блокировки	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	✓	●	●	●	●	●	●	●	●	●	●	●	●		●			○		
3 SQL-инъекция через email	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	✓	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●		●
2 **Лучше:** пагинация в SQL (LIMIT/OFFSET) — снимает лишнюю запись на странице и отрицательный сдвиг, не грузит всё в память	✓	✓	✓	✓	✓	✓		✓										✓																			
2 нет проверки qty > 0	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●		✓	●		●	◐	◐					◐					◐			○	
2 **Лучше:** атомарный условный UPDATE статуса — снимает повторный возврат, возврат товара до смены статуса и гонку	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓			✓	✓																	
2 резерв не возвращается при сбое после резервирования	●	●	●	●	●	●	●	●	●	●	●	●	●	●	◐	●	✓		○		●	●	●								○						
2 > вместо >= для бесплатной доставки	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	✓	●	●	●	●	●	●	●	●	●	●	●	●	●	●					
2 лишний заказ на странице	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●		●	●	●	●	●	●	●	●	●	●	●	●	●	●	●		●	●	●
2 tags=[] по умолчанию	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	✓	●	●	●	●	◐	●	●	●	◐		●	◐	●	◐				◐	○
2 повторный возврат того же объекта	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●	✓	●	●	●	●	○	●	●		○		◐		●	◐	○	○	○		
1 **Лучше:** транзакция / контекст для резерва с откатом — резерв не теряется при сбое после резервирования	✓																✓													✓						
1 page < 1 — отрицательный сдвиг среза		✓													✓	✓	✓													✓				✓		
1 товар возвращается на склад до записи статуса	✓	✓	✓	✓			✓										✓																			
1 % и _ в email не экранированы в LIKE	✓	✓	✓		✓		✓		✓	✓	✓			✓		✓													✓							
1 tags.append меняет список вызывающего	✓	✓		✓	✓	✓	✓		✓	✓	✓	✓	✓	✓	✓	✓		✓			✓	✓	✓	✓	✓				✓								

Находка	MiniMax M3	Claude Opus 5.5	GPT-6.1 Terra Pro	Claude Sonnet 5.5	GPT-6.1 Sol	Gemini Argon · high	Claude Haiku 5.5	Qwen 3.8 Max Prim	MiMo V2.6 Pro	Muse Wonder	Grok 4.7	Kimi K3.1 Pro	Gemini Argon · mec	Step 5 Preview	Mistral Large 4	GLM 5.3 Prime	DeepSeek V4 Pro	Muse Spark	Gemini 3.8 Flash	DeepSeek V4.1 Flasl	Gemini 3.1 Pro	Nemotron 3 Ultra	Muse Glimmer 30B	Claude Opus 4.6	GPT-OSS 120B	GPT-OSS 20B	Mistral Medium 3.5	North Mini Code	Laguna XS 2.1	Command A+	Ministral 14B	Nemotron 3.5 Light	Codestral	LFM 2.5 2.6B	Ministral 8B	Nemotron 3.5 Bolt f	Ministral 3B
1 тег coupon у недействительного купона	✓	✓	✓			✓	✓		✓	✓		✓	✓	✓	✓	✓	✓	✓	✓	✓		✓		✓		✓	✓	✓			✓				✓		
1 соединение не закрывается при отсутствии купона	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓				✓					✓		✓

Ложные замечания

Утверждение не подтвердилось по коду. Штраф — по серьёзности, которую заявила модель: critical 9, major 3, minor 1.

▾ Отсутствие фильтрации по статусу заказа в методе find_orders — 1 мод.

storage.py:36 · почему неверно: фильтр по статусу спецификация не требует

Ministral 3B −9

▾ Некорректная обработка или форматирование отрицательных сумм в функции fmt() — 1 мод.

pricing.py:30-32 · почему неверно: fmt верен для неотрицательных сумм

Ministral 3B −9

▾ Погрешность округления или точности при вычислении налога в tax() — 1 мод.

pricing.py:17-19 · почему неверно: Decimal + ROUND_HALF_UP по спецификации

Ministral 3B −9

▾ Некорректный порядок применения скидки и расчёта subtotal для налогов и доставки — 1 мод.

orders.py:51-55 · почему неверно: скидка уже до налога и доставки

Ministral 3B −9

▾ Некорректное предположение о структуре кортежа items при распаковке в refund — 1 мод.

orders.py:64-66 · почему неверно: распаковка уже for sku, _, qty

Ministral 3B −9

▾ Потенциальное состояние гонки при освобождении товара (release) 1 мод.

orders.py:35 · почему неверно: release целиком под блокировкой

Ministral 8B −9

▾ Потенциальная SQL-инъекция через подстановку параметра column в ORDER BY 1 мод.

storage.py:31-36 · почему неверно: колонка из белого списка

Nemotron 3.5 Bolt E4B −3

▾ Неверное имя столбца order_id вместо id в SQL-запросе set_status 1 мод.

storage.py:55 · почему неверно: в коде WHERE id = ?

North Mini Code −3

Тест 2 · Загрузчик Kotlin, Android вес в общем 40 %

Реальный класс приложения (~600 строк): параллельная загрузка картинок из нескольких источников в запас с квотами, повторами и паузами. Версия до исправления реальных ошибок; в задании о них ни слова.

Моделей: 21, семейств: 14. Реальных находок и предложений: 23, из них серьёзных: 1. 100 баллов — всё, что нашёл кто-либо, с верными исправлениями и без ложных.

#	МОДЕЛЬ ↕	БАЛЛ ↕	СЕРЬЁЗНЫЕ ↕	РЕАЛЬНЫХ ↕	ЛОЖНЫХ (ШТРАФ) ↕
1	**MiniMax M3** MiniMax	**49.4**	1 из 1	9	0
2	**Grok 4.7** xAI	**46.4**	1 из 1	8	0
3	**Claude Haiku 5.5** Anthropic	**46.2**	1 из 1	8	0
4	**Gemini Argon · high** Google	**43.8**	0 из 1	12	0
5	**GPT-6.1 Terra Pro** OpenAI	**38.5**	1 из 1	7	0
6	**Step 5 Preview** StepFun	**34.8**	1 из 1	6	0
7	**GPT-6.1 Sol** OpenAI	**34.1**	1 из 1	5	0
8	**Gemini Argon · medium** Google	**33.4**	1 из 1	4	0
9	**Qwen 3.8 Max Prime** Qwen	**33.0**	1 из 1	7	0
10	**Kimi K3.1 Pro** Moonshot	**28.9**	1 из 1	5	0
11	**Claude Opus 5.5** Anthropic	**27.1**	0 из 1	7	0
12	**Claude Sonnet 5.5** Anthropic	**26.3**	0 из 1	9	0
13	**MiMo V2.6 Pro** Xiaomi	**18.5**	0 из 1	6	0
14	**DeepSeek V4.1 Flash** DeepSeek	**14.9**	0 из 1	4	0
15	**GLM 5.3 Prime** Z.ai	**14.3**	0 из 1	4	0
16	**Gemini 3.8 Flash** Google	**12.5**	0 из 1	3	0
17	**Muse Spark** Meta	**8.7**	0 из 1	4	0
18	**DeepSeek V4 Pro** DeepSeek	**6.9**	0 из 1	3	0
19	**Mistral Large 4** Mistral	**4.2**	0 из 1	2	0
20	**Gemini 3.1 Pro** Google	**0.1**	0 из 1	2	1 (−3)

#	МОДЕЛЬ ↕	БАЛЛ ↕	СЕРЬЁЗНЫЕ ↕	РЕАЛЬНЫХ ↕	ЛОЖНЫХ (ШТРАФ) ↕
21	**Nemotron 3 Ultra** NVIDIA	**0.0**	0 из 1	2	2 (−12)

Находки и предложения — от самых ценных

3 серьёзная 2 заметная 1 мелкая ● верное исправление ◐ частичное ○ нет / неверное ✓ найдено (у мелких и «лучше» исправление не оценивается)

▾ **3** проверка предела до скачивания, добавление после — параллельные потоки переполняют запас («63 из 50») — 9 мод. · 8 сем.

Fetcher.kt:509, 563 · серьёзная · цена 12.86

● MiniMax M3 ● Grok 4.7 ● Claude Haiku 5.5 ● GPT-6.1 Terra Pro ● Step 5 Preview ● GPT-6.1 Sol ● Gemini Argon · medium ● Qwen 3.8 Max Prime ● Kimi K3.1 Pro

▾ **2** «отстаёт» для исправного источника с малой долей / фильтрами — вечная догоняющая без предела — 2 мод. · 2 сем.

Fetcher.kt:245, 411-420 · заметная · цена 5.57

● Gemini Argon · medium ● Claude Opus 5.5

▾ **2** при запасе ≥ 80 % повтор отменяется — упавший источник не перепроверяется — 5 мод. · 4 сем.

Fetcher.kt:136, 418 · заметная · цена 5.14

● MiniMax M3 ◐ Gemini Argon · high ◐ GPT-6.1 Terra Pro ● DeepSeek V4.1 Flash ● Gemini 3.8 Flash

▾ **2** clearPool в checkScreenSize до проверок допуска — запас пуст до следующей разрешённой загрузки — 6 мод. · 5 сем.

Fetcher.kt:214, 244-248, 459 · заметная · цена 4.93

● Grok 4.7 ● Claude Haiku 5.5 ● Gemini Argon · high ◐ Step 5 Preview ◐ Claude Opus 5.5 ● GLM 5.3 Prime

▾ **2** **Лучше:** одно состояние / координатор вместо пяти флагов — снимает гонки перезапуска и отмены и потерю запроса на загрузку — 7 мод. · 6 сем.

предложение · цена 4.71

✓ MiniMax M3 ✓ Grok 4.7 ✓ Claude Haiku 5.5 ✓ Gemini Argon · high ✓ GPT-6.1 Sol ✓ Claude Sonnet 5.5 ✓ MiMo V2.6 Pro

▾ **1** фильтры (18+) проверяются до скачивания, не при добавлении — 2 мод. · 1 сем.

Fetcher.kt:517-520, 560-567 · мелкая · цена 1.93

✓ GPT-6.1 Terra Pro ✓ GPT-6.1 Sol

▾ 1 останов по cap/месту после одной неудачи — IOException, источник ложно «сломан» 2 мод. · 1 сем.

Fetcher.kt:498, 509 · мелкая · цена 1.93

✓ Claude Haiku 5.5 ✓ Claude Opus 5.5

▾ 1 при проверке восстановившегося — два поиска подряд 1 мод. · 1 сем.

Fetcher.kt:283-291 · мелкая · цена 1.93

✓ Gemini 3.1 Pro

▾ 1 nextResume берёт только будущие паузы — готовый источник ждёт чужую 1 мод. · 1 сем.

Fetcher.kt:68-72, 140-143 · мелкая · цена 1.93

✓ MiniMax M3

▾ 1 scheduleRetry не смотрит место на диске — холостые повторы 1 мод. · 1 сем.

Fetcher.kt:132-144 · мелкая · цена 1.93

✓ DeepSeek V4 Pro

▾ 1 отсеянные по цвету / дубликаты не считаются в ok — одна битая картинка объявляет рабочий источник сломанным 2 мод. · 1 сем.

Fetcher.kt:498-500, 545-559, 574 · мелкая · цена 1.93

✓ Claude Opus 5.5 ✓ Claude Sonnet 5.5

▾ 1 **Лучше:** временный файл + rename после addUnique — недописанный файл не остаётся в запасе 1 мод. · 1 сем.

предложение · цена 1.93

✓ MiMo V2.6 Pro

▾ 1 **Лучше:** проверка упавших источников отдельным шагом до квот — упавший перепроверяется и при полном запасе 1 мод. · 1 сем.

предложение · цена 1.93

✓ DeepSeek V4.1 Flash

▾ 1 нет раннего выхода при серии сетевых ошибок — перебор всех кандидатов по таймаутам — 2 мод. · 2 сем.

Fetcher.kt:508-592 · мелкая · цена 1.86

✓ Gemini Argon · high ✓ Claude Sonnet 5.5

▾ 1 избыток NSFW у Wallhaven не вычитается — квота источника превышается — 2 мод. · 2 сем.

Fetcher.kt:317-321 · мелкая · цена 1.86

✓ MiniMax M3 ✓ Gemini Argon · high

▾ 1 onAvailable не учитывает догоняющую — 3 мод. · 3 сем.

Fetcher.kt:177-182 · мелкая · цена 1.79

✓ Gemini Argon · high ✓ GLM 5.3 Prime ✓ Muse Spark

▾ 1 testSource с неизвестным ключом не вызывает done — 5 мод. · 4 сем.

Fetcher.kt:391-394 · мелкая · цена 1.71

✓ Grok 4.7 ✓ Gemini Argon · high ✓ Qwen 3.8 Max Prime ✓ Kimi K3.1 Pro ✓ Gemini 3.8 Flash

▾ 1 refill из «Проверить» теряется, если загрузка уже идёт — 5 мод. · 4 сем.

Fetcher.kt:205, 402 · мелкая · цена 1.71

✓ Grok 4.7 ✓ Gemini Argon · high ✓ GPT-6.1 Terra Pro ✓ Gemini Argon · medium ✓ Claude Sonnet 5.5

▾ 1 результат compress не проверяется — 9 мод. · 8 сем.

Fetcher.kt:561 · мелкая · цена 1.43

✓ MiniMax M3 ✓ Grok 4.7 ✓ Gemini Argon · high ✓ Step 5 Preview ✓ Qwen 3.8 Max Prime ✓ Kimi K3.1 Pro ✓ Claude Opus 5.5 ✓ Claude Sonnet 5.5 ✓ MiMo V2.6 Pro

▾ 1 parallel глотает исключения задач (в т.ч. OOM) — 9 мод. · 8 сем.

Fetcher.kt:364-366 · мелкая · цена 1.43

✓ Claude Haiku 5.5 ✓ Gemini Argon · high ✓ GPT-6.1 Terra Pro ✓ Step 5 Preview ✓ Qwen 3.8 Max Prime ✓ Kimi K3.1 Pro ✓ Claude Sonnet 5.5 ✓ Mistral Large 4 ✓ Nemotron 3 Ultra

▾ 1 cancel.set(false) в начале задачи стирает отмену, выставленную до старта — 11 мод. · 9 сем.

Fetcher.kt:193-195, 205-210 · мелкая · цена 1.36

✓ MiniMax M3 ✓ Claude Haiku 5.5 ✓ GPT-6.1 Terra Pro ✓ Step 5 Preview ✓ Qwen 3.8 Max Prime ✓ Claude Sonnet 5.5 ✓ MiMo V2.6 Pro ✓ DeepSeek V4.1 Flash ✓ GLM 5.3 Prime ✓ Muse Spark ✓ DeepSeek V4 Pro

▾ 1 restartPending теряется / повисает на стыке running.set(false) и проверки — 13 мод. · 10 сем.

Fetcher.kt:192-200, 223-228 · мелкая · цена 1.29

✓ MiniMax M3 ✓ Grok 4.7 ✓ Claude Haiku 5.5 ✓ Gemini Argon · high ✓ GPT-6.1 Sol ✓ Gemini Argon · medium ✓ Qwen 3.8 Max Prime ✓ Claude Opus 5.5 ✓ Claude Sonnet 5.5 ✓ MiMo V2.6 Pro ✓ Muse Spark ✓ Mistral Large 4 ✓ Nemotron 3 Ultra

▾ 1 файл в pool/ остаётся при сбое записи/addUnique — 18 мод. · 12 сем.

Fetcher.kt:560-573, 581-590 · мелкая · цена 1.14

✓ MiniMax M3 ✓ Grok 4.7 ✓ Claude Haiku 5.5 ✓ Gemini Argon · high ✓ GPT-6.1 Terra Pro ✓ Step 5 Preview ✓ GPT-6.1 Sol ✓ Qwen 3.8 Max Prime ✓ Kimi K3.1 Pro ✓ Claude Opus 5.5 ✓ Claude Sonnet 5.5 ✓ MiMo V2.6 Pro ✓ DeepSeek V4.1 Flash ✓ GLM 5.3 Prime ✓ Gemini 3.8 Flash ✓ Muse Spark ✓ DeepSeek V4 Pro ✓ Gemini 3.1 Pro

▾ **Матрица «находка × модель»** — кто что нашёл

Находка	MiniMax M3	Grok 4.7	Claude Haiku 5.5	Gemini Argon · high	GPT-6.1 Terra Pro	Step 5 Preview	GPT-6.1 Sol	Gemini Argon · medium	Qwen 3.8 Max Prime	Kimi K3.1 Pro	Claude Opus 5.5	Claude Sonnet 5.5	MiMo V2.6 Pro	DeepSeek V4.1 Flash	GLM 5.3 Prime	Gemini 3.8 Flash	Muse Spark	DeepSeek V4 Pro	Mistral Large 4	Gemini 3.1 Pro	Nemotron 3 Ultra
3 проверка предела до скачивания, добавление после — параллельные потоки переполняют запас («63 из 50»)	●	●	●		●	●	●	●	●	●											
2 «отстаёт» для исправного источника с малой долей / фильтрами — вечная догоняющая без предела								●			●										
2 при запасе ≥ 80 % повтор отменяется — упавший источник не перепроверяется	●			◐	◐									●		●					
2 clearPool в checkScreenSize до проверок допуска — запас пуст до следующей разрешённой загрузки		●	●	●		◐					◐				●						
2 **Лучше:** одно состояние / координатор вместо пяти флагов — снимает гонки перезапуска и отмены и потерю запроса на загрузку	✓	✓	✓	✓			✓					✓	✓								
1 фильтры (18+) проверяются до скачивания, не при добавлении					✓		✓														
1 останов по cap/месту после одной неудачи — IOException, источник ложно «сломан»			✓								✓										
1 при проверке восстановившегося — два поиска подряд																				✓	
1 nextResume берёт только будущие паузы — готовый источник ждёт чужую	✓																				
1 scheduleRetry не смотрит место на диске — холостые повторы																		✓			
1 отсеянные по цвету / дубликаты не считаются в ok — одна битая картинка объявляет рабочий источник сломанным											✓	✓									
1 **Лучше:** временный файл + rename после addUnique — недописанный файл не остаётся в запасе													✓								
1 **Лучше:** проверка упавших источников отдельным шагом до квот — упавший перепроверяется и при полном запасе														✓							
1 нет раннего выхода при серии сетевых ошибок — перебор всех кандидатов по таймаутам				✓								✓									
1 избыток NSFW у Wallhaven не вычитается — квота источника превышается	✓			✓																	
1 onAvailable не учитывает догоняющую				✓											✓		✓				
1 testSource с неизвестным ключом не вызывает done		✓		✓					✓	✓						✓					

Находка	MiniMax M3	Grok 4.7	Claude Haiku 5.5	Gemini Argon · high	GPT-6.1 Terra Pro	Step 5 Preview	GPT-6.1 Sol	Gemini Argon · mec	Qwen 3.8 Max Prim	Kimi K3.1 Pro	Claude Opus 5.5	Claude Sonnet 5.5	MiMo V2.6 Pro	DeepSeek V4.1 Flasl	GLM 5.3 Prime	Gemini 3.8 Flash	Muse Spark	DeepSeek V4 Pro	Mistral Large 4	Gemini 3.1 Pro	Nemotron 3 Ultra
1 refill из «Проверить» теряется, если загрузка уже идёт		✓		✓	✓			✓				✓									
1 результат compress не проверяется	✓	✓		✓		✓			✓	✓	✓	✓	✓								
1 parallel глотает исключения задач (в т.ч. OOM)			✓	✓	✓	✓			✓	✓		✓							✓		✓
1 cancel.set(false) в начале задачи стирает отмену, выставленную до старта	✓		✓		✓	✓			✓			✓	✓	✓	✓		✓	✓			
1 restartPending теряется / повисает на стыке running.set(false) и проверки	✓	✓	✓	✓			✓	✓	✓		✓	✓	✓				✓		✓		✓
1 файл в pool/ остаётся при сбое записи/addUnique	✓	✓	✓	✓	✓	✓	✓		✓	✓	✓	✓	✓	✓	✓	✓	✓	✓		✓	

Ложные замечания

Утверждение не подтвердилось по коду. Штраф — по серьёзности, которую заявила модель: critical 9, major 3, minor 1.

▾ Утечка сетевого колбэка: watchNetwork регистрирует NetworkCallback, но никогда не снимает регистрацию — 1 мод.

Fetcher.kt:167-185 · почему неверно: колбэк регистрируется один раз (watching) — не «копится»

Nemotron 3 Ultra −9

▾ Вызов cur.getDelay() в setRetry после проверки !cur.isDone() подвержен гонке и может выбросить IllegalStateException при завершении задачи — 1 мод.

Fetcher.kt:153-154 · почему неверно: getDelay у завершённой задачи не бросает — вернёт ≤ 0

Nemotron 3 Ultra −3

▾ Оптимизация обращений к SQLite: отказ от проверки Store.poolCount и переменной cap в цикле скачивания в пользу остановки по рассчитанной квоте — 1 мод.

· почему неверно: «убрать cap — квот достаточно»: без предела было 225 из 200 (комментарий стр. 426)

Gemini 3.1 Pro −3

Тест 3 · Маршруты A* Python вес в общем 40 %

Реальный модуль планировщика (2 файла, ~1000 строк): поиск пути A* по сетке со стенами и платными воротами, склейка маршрута по точкам. Версия до исправления реальной ошибки.

Моделей: 20, семейств: 13. Реальных находок и предложений: 18, из них серьёзных: 1. 100 баллов — всё, что нашёл кто-либо, с верными исправлениями и без ложных.

#	МОДЕЛЬ	БАЛЛ	СЕРЬЁЗНЫЕ	РЕАЛЬНЫХ	ЛОЖНЫХ (ШТРАФ)
1	**Gemini Argon · high** Google	70.9	1 из 1	12	0
2	**Claude Haiku 5.5** Anthropic	69.9	1 из 1	11	0
3	**Claude Opus 5.5** Anthropic	66.6	1 из 1	9	0
4	**Claude Sonnet 5.5** Anthropic	62.3	1 из 1	8	0
5	**GPT-6.1 Sol** OpenAI	61.2	1 из 1	8	0
6	**GPT-6.1 Terra Pro** OpenAI	59.4	1 из 1	8	0
7	**MiMo V2.6 Pro** Xiaomi	57.9	1 из 1	8	0
8	**Gemini 3.1 Pro** Google	55.3	1 из 1	8	0
9	**Kimi K3.1 Pro** Moonshot	51.1	1 из 1	6	0
10	**DeepSeek V4.1 Flash** DeepSeek	50.2	1 из 1	7	0
11	**Mistral Large 4** Mistral	38.3	1 из 1	6	1 (−1)
12	**Qwen 3.8 Max Prime** Qwen	37.9	0 из 1	7	0
13	**Grok 4.7** xAI	33.8	0 из 1	6	0
14	**Gemini 3.8 Flash** Google	33.4	0 из 1	7	0
15	**Muse Spark** Meta	31.3	0 из 1	7	0
16	**Gemini Argon · medium** Google	28.7	0 из 1	6	0
17	**Nemotron 3 Ultra** NVIDIA	27.1	1 из 1	3	0
18	**Step 5 Preview** StepFun	24.0	1 из 1	2	0
19	**DeepSeek V4 Pro** DeepSeek	18.0	0 из 1	3	0
20	**MiniMax M3** MiniMax	10.8	0 из 1	2	0

Находки и предложения — от самых ценных

3 серьёзная 2 заметная 1 мелкая ● верное исправление ◐ частичное ○ нет / неверное ✓ найдено (у мелких и «лучше» исправление не оценивается)

▾ **3** окно поиска «старт/цель ± 40 клеток» отсекает обход длинной стены — путь есть, а ответ «нет маршрута» — 13 мод. · 9 сем.

pathfinder.py:359-366 · серьёзная · цена 11.77

◐ Gemini Argon · high | ◐ Claude Haiku 5.5 | ● Claude Opus 5.5 | ● Claude Sonnet 5.5 | ◐ GPT-6.1 Sol | ◐ GPT-6.1 Terra Pro | ● MiMo V2.6 Pro | ◐ Gemini 3.1 Pro | ● Kimi K3.1 Pro | ◐ DeepSeek V4.1 Flash | ◐ Mistral Large 4 | ◐ Nemotron 3 Ultra | ◐ Step 5 Preview

▾ **2** _cells_near_segment перебирает весь bbox отрезка: длинная диагональ / большая толщина из веб-документа — секунды CPU и память — 11 мод. · 6 сем.

pathfinder.py:416-431 · заметная · цена 4.62

● Gemini Argon · high | ● Claude Haiku 5.5 | ● Claude Opus 5.5 | ◐ Claude Sonnet 5.5 | ● GPT-6.1 Sol | ● GPT-6.1 Terra Pro | ● Gemini 3.1 Pro | ● DeepSeek V4.1 Flash | ● Qwen 3.8 Max Prime | ◐ Grok 4.7 | ● Gemini 3.8 Flash

▾ **2** растеризация по одному сегменту: ворота пробивают ранее нарисованные стены, поздняя стена закрывает ворота — проходимость зависит от порядка — 15 мод. · 10 сем.

pathfinder.py:84-114 · заметная · цена 3.69

◐ Gemini Argon · high | ● Claude Haiku 5.5 | ◐ Claude Opus 5.5 | ● Claude Sonnet 5.5 | ● GPT-6.1 Sol | ● GPT-6.1 Terra Pro | ● MiMo V2.6 Pro | ● Kimi K3.1 Pro | ◐ Mistral Large 4 | ◐ Qwen 3.8 Max Prime | ● Grok 4.7 | ◐ Gemini 3.8 Flash | ◐ Muse Spark | ◐ Gemini Argon · medium | ◐ DeepSeek V4 Pro

▾ **2** при промежуточных точках каждый кусок с пустым paid, штрафы складываются — нарушено «once per path» из докстринга — 16 мод. · 10 сем.

planner.py:70, 83-94, 343 · заметная · цена 3.69

◐ Gemini Argon · high | ● Claude Haiku 5.5 | ● Claude Opus 5.5 | ● Claude Sonnet 5.5 | ● GPT-6.1 Sol | ● GPT-6.1 Terra Pro | ● MiMo V2.6 Pro | ● Gemini 3.1 Pro | ● Kimi K3.1 Pro | ◐ DeepSeek V4.1 Flash | ● Qwen 3.8 Max Prime | ● Grok 4.7 | ● Muse Spark | ● Gemini Argon · medium | ● DeepSeek V4 Pro | ● MiniMax M3

▾ **1** forbidden из одной точки с воротами отбрасывается, хотя Pathfinder такие поддерживает — 2 мод. · 2 сем.

planner.py:524 · мелкая · цена 1.85

✓ Qwen 3.8 Max Prime | ✓ Gemini Argon · medium

▾ 1 fast == short: в «short» берётся геометрический путь без проверки, что он не длиннее — 2 мод. · 2 сем.

planner.py:410 · мелкая · цена 1.85

✓ Claude Haiku 5.5 ✓ Grok 4.7

▾ 1 **Лучше:** растеризация только в окне поиска / пространственный индекс — без перебора всей карты — 2 мод. · 2 сем.

предложение · цена 1.85

✓ GPT-6.1 Sol ✓ Kimi K3.1 Pro

▾ 1 _mid_path_block накрывает 5×5 и соседей промежуточной точки — альтернативный коридор молча не строится — 5 мод. · 3 сем.

planner.py:187-201, 311-321 · мелкая · цена 1.77

✓ Gemini Argon · high ✓ Claude Sonnet 5.5 ✓ MiMo V2.6 Pro ✓ Gemini 3.1 Pro ✓ Gemini 3.8 Flash

▾ 1 start/goal не проверяются на _blocked: точка в тонкой стене даёт пройти сквозь неё; из толстой полосы не выйти — 7 мод. · 4 сем.

pathfinder.py:169-174, 296-301 · мелкая · цена 1.69

✓ Gemini Argon · high ✓ Claude Opus 5.5 ✓ GPT-6.1 Sol ✓ GPT-6.1 Terra Pro ✓ Gemini 3.8 Flash ✓ Gemini Argon · medium ✓ DeepSeek V4 Pro

▾ 1 состояние (клетка, frozenset ворот) растёт экспоненциально при многих воротах, лимита раскрытий нет — 5 мод. · 4 сем.

pathfinder.py:145, 183 · мелкая · цена 1.69

✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ GPT-6.1 Sol ✓ DeepSeek V4.1 Flash ✓ Gemini Argon · medium

▾ 1 thickness 0 → «or 2» превращает в 2 — 4 мод. · 4 сем.

planner.py:527 · мелкая · цена 1.69

✓ Gemini Argon · high ✓ MiMo V2.6 Pro ✓ Mistral Large 4 ✓ Qwen 3.8 Max Prime

▾ 1 окно time-based включает все линии размещения карты — сетка раздувается — 4 мод. · 4 сем.

pathfinder.py:345-357 · мелкая · цена 1.69

✓ Claude Opus 5.5 ✓ MiMo V2.6 Pro ✓ Gemini 3.8 Flash ✓ Muse Spark

▾ 1 **Лучше:** растеризация вдоль линии вместо перебора всего прямоугольника отрезка — 5 мод. · 4 сем.

предложение · цена 1.69

✓ Claude Haiku 5.5 ✓ Claude Opus 5.5 ✓ GPT-6.1 Sol ✓ Gemini 3.1 Pro ✓ Muse Spark

▾ 1 диагональный шаг без проверки углов: стена тоньше ~1.42 протекает (по умолчанию толщина 2 — не протекает) — 6 мод. · 5 сем.

pathfinder.py:168-174, 384-393 · мелкая · цена 1.62

✓ Gemini Argon · high ✓ Claude Opus 5.5 ✓ Claude Sonnet 5.5 ✓ GPT-6.1 Terra Pro ✓ Kimi K3.1 Pro ✓ Muse Spark

▾ 1 evaluate_existing_path: penalty_time=0 — нарисованный через ворота маршрут оценивается без штрафа — 6 мод. · 6 сем.

planner.py:424-462 · мелкая · цена 1.54

✓ Claude Haiku 5.5 ✓ Gemini 3.1 Pro ✓ DeepSeek V4.1 Flash ✓ Mistral Large 4 ✓ Muse Spark ✓ Nemotron 3 Ultra

▾ 1 gate['position'][0] без проверки длины и т.п. — повреждённый документ роняет планирование — 11 мод. · 7 сем.

planner.py:486-508, 526 · мелкая · цена 1.46

✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ Claude Sonnet 5.5 ✓ MiMo V2.6 Pro ✓ Gemini 3.1 Pro ✓ DeepSeek V4.1 Flash ✓ Mistral Large 4 ✓ Qwen 3.8 Max Prime ✓ Gemini 3.8 Flash ✓ Gemini Argon · medium ✓ Step 5 Preview

▾ 1 перекрытие 3×3 соседних ворот — _cell_to_gate хранит последние, штраф первых теряется — 9 мод. · 8 сем.

pathfinder.py:106-109 · мелкая · цена 1.38

✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ GPT-6.1 Terra Pro ✓ Gemini 3.1 Pro ✓ Mistral Large 4 ✓ Grok 4.7 ✓ Muse Spark ✓ Nemotron 3 Ultra ✓ MiniMax M3

▾ 1 pathfinder подменяет flight_speed=0 дефолтом, planner делит на 0 — 11 мод. · 8 сем.

planner.py:113-119, 169 · мелкая · цена 1.38

✓ Gemini Argon · high ✓ Claude Haiku 5.5 ✓ Claude Opus 5.5 ✓ Claude Sonnet 5.5 ✓ GPT-6.1 Terra Pro ✓ MiMo V2.6 Pro ✓ Kimi K3.1 Pro ✓ DeepSeek V4.1 Flash ✓ Qwen 3.8 Max Prime ✓ Grok 4.7 ✓ Gemini 3.8 Flash

▾ **Матрица «находка × модель»** — кто что нашёл

Находка	Gemini Argon · high	Claude Haiku 5.5	Claude Opus 5.5	Claude Sonnet 5.5	GPT-6.1 Sol	GPT-6.1 Terra Pro	MiMo V2.6 Pro	Gemini 3.1 Pro	Kimi K3.1 Pro	DeepSeek V4.1 Flash	Mistral Large 4	Qwen 3.8 Max Prime	Grok 4.7	Gemini 3.8 Flash	Muse Spark	Gemini Argon · medium	Nemotron 3 Ultra	Step 5 Preview	DeepSeek V4 Pro	MiniMax M3
3 окно поиска «старт/цель ± 40 клеток» отсекает обход длинной стены — путь есть, а ответ «нет маршрута»	◐	◐	•	•	◐	◐	•	◐	•	◐	◐						◐	◐		
2 _cells_near_segment перебирает весь bbox отрезка: длинная диагональ / большая толщина из веб-документа — секунды CPU и память	•	•	•	◐	•	•		•		•		•	◐	•						
2 растеризация по одному сегменту: ворота пробивают ранее нарисованные стены, поздняя стена закрывает ворота — проходимость зависит от порядка	◐	•	◐	•	•	•	•		•		◐	◐	•	◐	◐	◐			◐	
2 при промежуточных точках каждый кусок с пустым paid, штрафы складываются — нарушено «once per path» из докстринга	◐	•	•	•	•	•	•	•	•	◐		•	•		•	•			•	•
1 forbidden из одной точки с воротами отбрасывается, хотя Pathfinder такие поддерживает												✓				✓				
1 fast == short: в «short» берётся геометрический путь без проверки, что он не длиннее		✓											✓							
1 **Лучше:** растеризация только в окне поиска / пространственный индекс — без перебора всей карты					✓				✓											
1 _mid_path_block накрывает 5×5 и соседей промежуточной точки — альтернативный коридор молча не строится	✓			✓			✓	✓						✓						
1 start/goal не проверяются на _blocked: точка в тонкой стене даёт пройти сквозь неё; из толстой полосы не выйти	✓		✓		✓	✓								✓		✓			✓	
1 состояние (клетка, frozenset ворот) растёт экспоненциально при многих воротах, лимита раскрытий нет	✓	✓			✓					✓						✓				
1 thickness 0 → «or 2» превращает в 2	✓						✓				✓	✓								
1 окно time-based включает все линии размещения карты — сетка раздувается			✓				✓							✓	✓					
1 **Лучше:** растеризация вдоль линии вместо перебора всего прямоугольника отрезка		✓	✓		✓			✓							✓					
1 диагональный шаг без проверки углов: стена тоньше ~1.42 протекает (по умолчанию толщина 2 — не протекает)	✓		✓	✓		✓			✓						✓					
1 evaluate_existing_path: penalty_time=0 — нарисованный через ворота маршрут оценивается без штрафа		✓						✓		✓	✓				✓		✓			

Находка	Gemini Argon · high	Claude Haiku 5.5	Claude Opus 5.5	Claude Sonnet 5.5	GPT-6.1 Sol	GPT-6.1 Terra Pro	MiMo V2.6 Pro	Gemini 3.1 Pro	Kimi K3.1 Pro	DeepSeek V4.1 Flash	Mistral Large 4	Qwen 3.8 Max Prim	Grok 4.7	Gemini 3.8 Flash	Muse Spark	Gemini Argon · mec	Nemotron 3 Ultra	Step 5 Preview	DeepSeek V4 Pro	MiniMax M3
1 gate['position'][0] без проверки длины и т.п. — повреждённый документ роняет планирование	✓	✓		✓			✓	✓		✓	✓	✓		✓		✓		✓		
1 перекрытие 3×3 соседних ворот — _cell_to_gate хранит последние, штраф первых теряется	✓	✓				✓		✓			✓		✓		✓		✓			✓
1 pathfinder подменяет flight_speed=0 дефолтом, planner делит на 0	✓	✓	✓	✓		✓	✓		✓	✓		✓	✓	✓						

Ложные замечания

Утверждение не подтвердилось по коду. Штраф — по серьёзности, которую заявила модель: critical 9, major 3, minor 1.

▾ Слишком большая погрешность допуска (1.0) в _same_path ошибочно отбрасывает близкие альтернативные маршруты — 1 мод.

planner.py:465-473 · почему неверно: клетки целые: |Δ| < 1.0 — это точное совпадение, близкие пути не отбрасываются

Mistral Large 4 −1

Методика

Задания

- **Тест 1 · Магазин** (Python) — Учебный сервис заказов (3 файла, ~150 строк) с заложенными ошибками и ловушками — правильным кодом, похожим на ошибку. Лёгкий: отсеивает слабые модели.
- **Тест 2 · Загрузчик** (Kotlin, Android) — Реальный класс приложения (~600 строк): параллельная загрузка картинок из нескольких источников в запас с квотами, повторами и паузами. Версия до исправления реальных ошибок; в задании о них ни слова.
- **Тест 3 · Маршруты A*** (Python) — Реальный модуль планировщика (2 файла, ~1000 строк): поиск пути A* по сетке со стенами и платными воротами, склейка маршрута по точкам. Версия до исправления реальной ошибки.

Тесты 2 и 3 — реальный код из проектов автора, взятый в версии до исправления найденных в работе ошибок. В задании нет подсказок, где ошибка: только требования к коду, сам код с номерами строк и просьба найти ошибки, предложить исправления и, если есть, решение лучше.

Как запускали

- Один и тот же бриф (по-русски) и одно и то же задание байт в байт для всех; ответ — списком «[серьёзность] файл:строка — суть; сценарий; исправление; уверенность».
- Модели — на высоком уровне рассуждений: Claude — xhigh (Claude Code в изоляции, без инструментов и своих правил), остальные — high у своего провайдера (OpenRouter, веб Gemini, Antigravity, API Mistral и NVIDIA).
- Один прогон на модель. Повтор той же модели может дать ±10–15 баллов: главную ошибку теста она то находит, то нет.
- Модели, работающие как агент (Gemini в Antigravity, Claude Code), запускались в изолированной песочнице без доступа к файлам и без общих инструкций.

Оценка — вслепую

- Все ответы теста получают случайные номера; замечания сводит в группы Gemini Flash («одна причина в одном месте — одна группа»), не зная, где чей ответ.
- Каждую группу проверяет по коду Claude (тоже по номерам): **реальная** (важность 3 серьёзная / 2 заметная / 1 мелкая), **придирка** или **спорное** (0 баллов), **ложная** (штраф). Задуманное автором кода и подтверждённое комментарием в коде — не ошибка.
- У серьёзных и заметных находок отдельно оценивается исправление: верное (снимает причину и не ломает другое), частичное (снимает симптом или создаёт новую проблему), нет / неверное.
- Предложения «лучше» (другой подход, а не исправление одной ошибки) — своими группами; цена — по тому, что они реально снимают. Общие советы без привязки к найденным проблемам («переписать на …») — 0.

Баллы

- Цена находки = важность (1 / 3 / 9) × редкость (2 − доля семейств, где её нашла хоть одна модель). Редкость считается по семействам: три модели одного разработчика, нашедшие одно и то же, — одно семейство.
- У находок важности 2–3: ⅔ цены — за то, что найдено, ⅓ — за исправление (1 / 0.5 / 0).
- Ложное замечание — минус по заявленной серьёзности: critical 9, major 3, minor 1.
- Балл теста = (набранное − штрафы) / всё, что нашли модели таблицы, × 100, не ниже 0.
- Общий = 20 % теста 1 + 40 % теста 2 + 40 % теста 3.

Ограничения

- Три задания, два из них — реальный код; один прогон на модель.
- Оценивает модель Claude — вслепую, но её представление о «реальной ошибке» может быть ближе к стилю своих моделей. Частично это снимают сведение групп другой моделью и сверка серьёзности с реальными исправлениями.
- Ответ без инструментов: модели не могли запустить код и проверить догадку.

Сводка находок и оценки — вслепую: номера ответов без имён моделей. Код заданий и тексты ответов не публикуются.